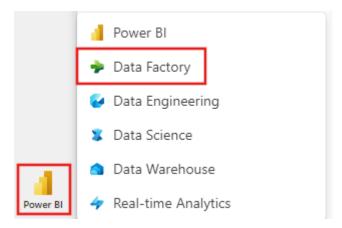
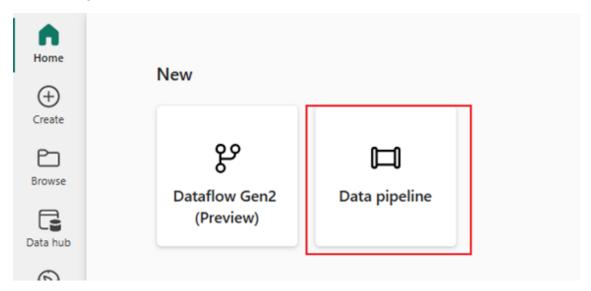
Crear un pipeline con Data Factory

Crear una canalización de datos

1. Seleccione el ícono predeterminado de Power BI en la parte inferior izquierda de la pantalla y cambie a la experiencia **de Data Factory** .



2. Seleccione **Canalización de datos** y proporcione un nombre de canalización. Luego, seleccione **Crear** .



New pipeline

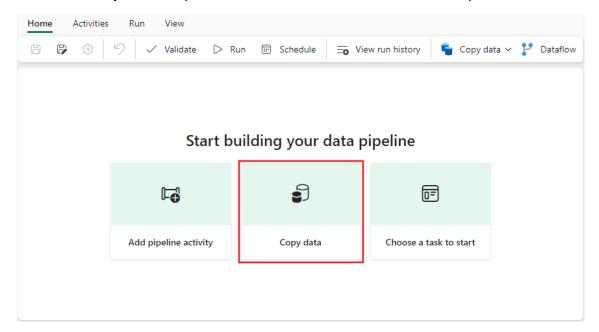


Name



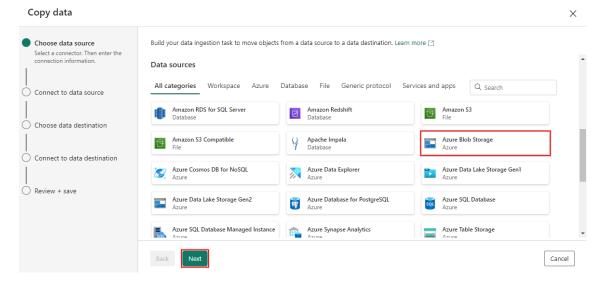
Utilice una actividad de copia en la canalización para cargar datos de muestra en un lago de datos

Seleccione **Copiar datos** para abrir la herramienta del asistente de copia.

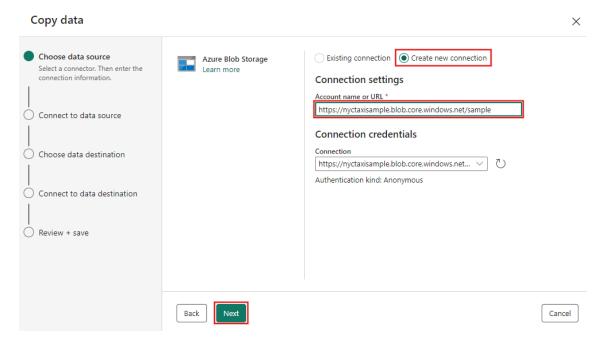


Paso 2: Configure sus ajustes en el asistente de copia.

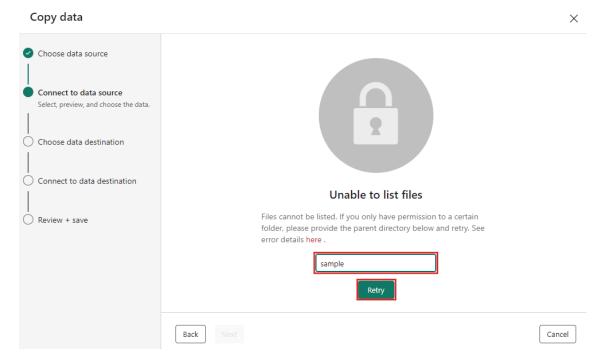
 Se muestra el cuadro de diálogo Copiar datos con el primer paso, Elegir origen de datos, resaltado. Desplácese hacia abajo, si es necesario, hasta la sección Orígenes de datos y seleccione el tipo de origen de datos de Azure Blob Storage. A continuación, seleccione Siguiente.



2. En el siguiente paso, seleccione **Crear nueva conexión** y, a continuación, proporcione la URL del almacenamiento de blobs que aloja los datos de muestra proporcionados para este tutorial en https://nyctaxisample.blob.core.windows.net/sample. El tipo de autenticación es **Anónimo** . Seleccione **Siguiente** después de proporcionar la URL.



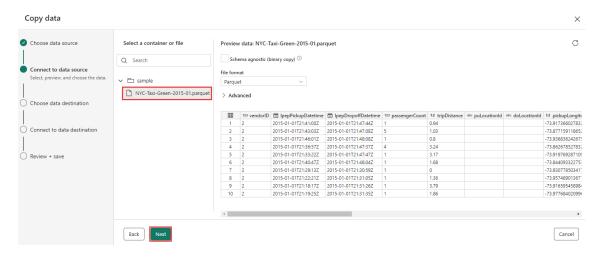
3. Aparece el paso Conectar a la fuente de datos y, al principio, aparece un error No se pueden enumerar los archivos porque solo se han otorgado permisos a la carpeta sample en el almacenamiento de blobs. Proporcione el nombre de la carpeta, sample y seleccione Reintentar.



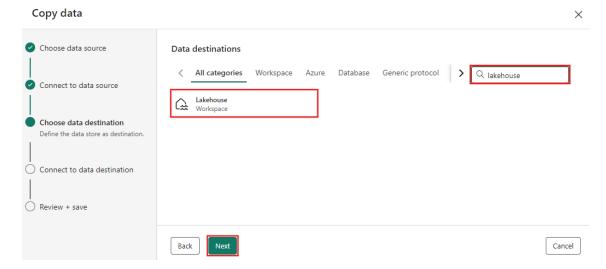
Nota

La carpeta de almacenamiento de blobs distingue entre mayúsculas y minúsculas y debe estar en minúsculas.

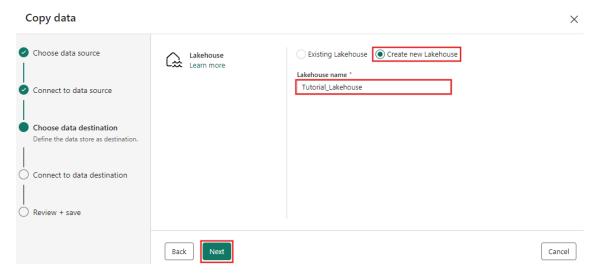
4. A continuación, aparece el explorador de almacenamiento de blobs. Seleccione el archivo **NYC-Taxi-Green-2015-01.parquet** y espere a que aparezca la vista previa de los datos. Luego, seleccione **Siguiente** .



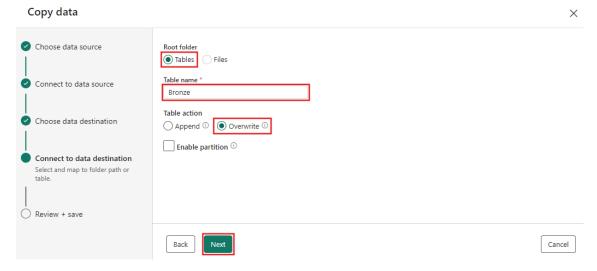
5. Para el paso **Elegir destino de datos** del asistente de copia, seleccione **Lakehouse** y luego **Siguiente** .



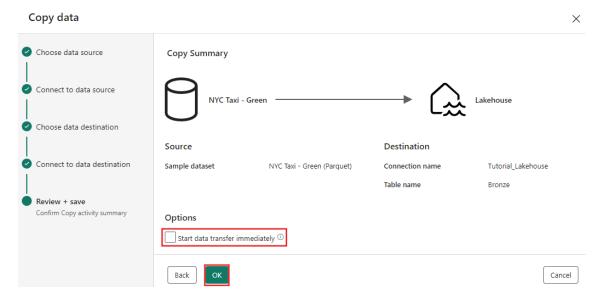
6. Seleccione **Crear nuevo Lakehouse** en la página de configuración de destino de datos que aparece e ingrese un nombre para el nuevo Lakehouse. Luego, seleccione **Siguiente** nuevamente.



7. Ahora configure los detalles de su destino Lakehouse en la página Seleccionar y asignar a la ruta de la carpeta o tabla. Seleccione Tablas para la carpeta raíz, proporcione un nombre de tabla y elija la acción Sobrescribir. No marque la casilla de verificación Habilitar partición que aparece después de seleccionar la acción Sobrescribir tabla.

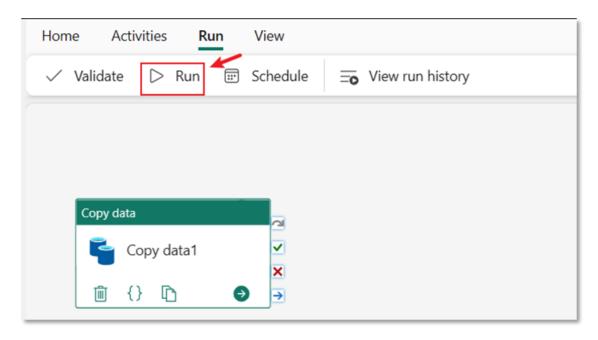


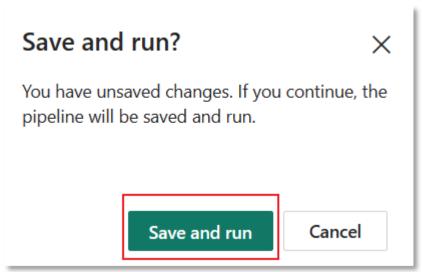
8. Por último, en la página **Revisar + guardar** del asistente de copia de datos, revise la configuración. Para este tutorial, desmarque la casilla **Iniciar transferencia de datos inmediatamente**, ya que ejecutaremos la actividad manualmente en el siguiente paso. Luego, seleccione **Aceptar**.



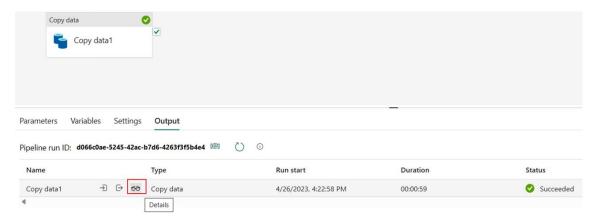
Paso 3: Ejecute y visualice los resultados de su actividad de copia.

 Seleccione la pestaña Ejecutar en el editor de canalización. Luego, seleccione el botón Ejecutar y, luego, Guardar y ejecutar en el mensaje que se le solicite para ejecutar la actividad Copiar.





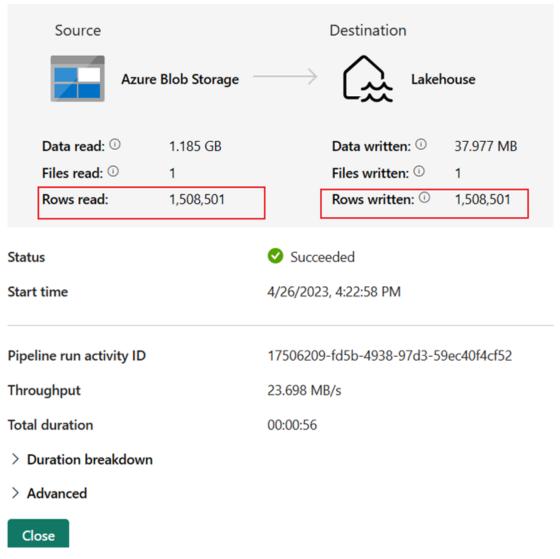
2. Puede supervisar la ejecución y comprobar los resultados en la pestaña **Salida**, debajo del lienzo de la canalización. Seleccione el botón de detalles de la ejecución (el icono de "anteojos" que aparece cuando pasa el cursor sobre la ejecución de la canalización en ejecución) para ver los detalles de la ejecución.



3. Los detalles de la ejecución muestran 1.508.501 filas leídas y escritas.

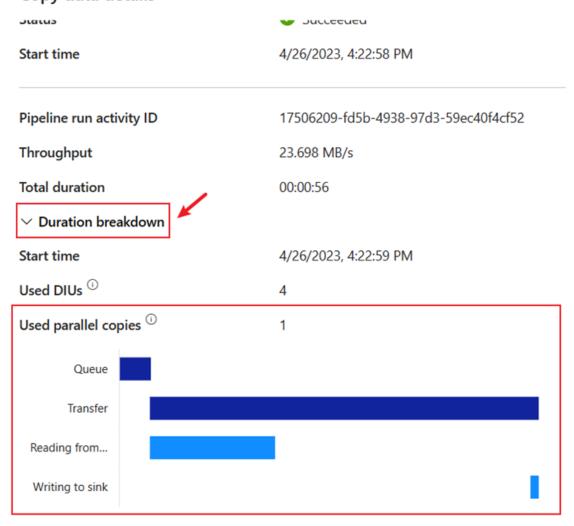
Copy data details

Copy data1



4. Expande la sección **Desglose de duración** para ver la duración de cada etapa de la actividad de copia. Después de revisar los detalles de la copia, selecciona **Cerrar** .

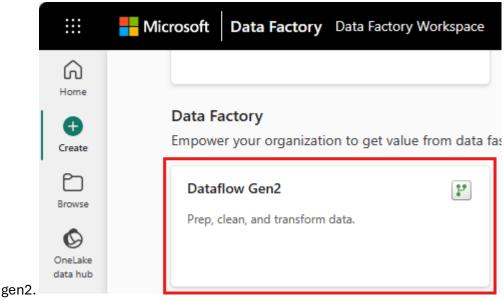
Copy data details



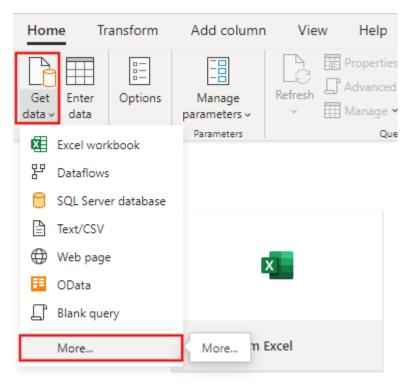
> Advanced

Obtener datos de una tabla de Lakehouse

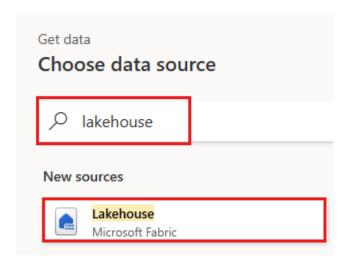
1. Desde la barra lateral, seleccione **Crear** y luego **Dataflow Gen2** para crear un nuevo flujo de datos



2. Desde el nuevo menú de flujo de datos, seleccione Obtener datos y luego Más....



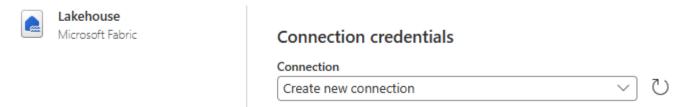
3. Busque y seleccione el conector **Lakehouse** .



4. Aparece el cuadro de diálogo **Conectarse a la fuente de datos** y se crea automáticamente una nueva conexión para usted en función del usuario que haya iniciado sesión actualmente. Seleccione **Siguiente**.

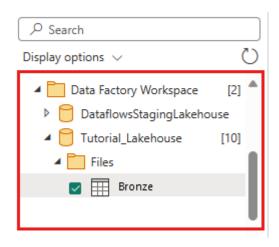
Get data

Connect to data source



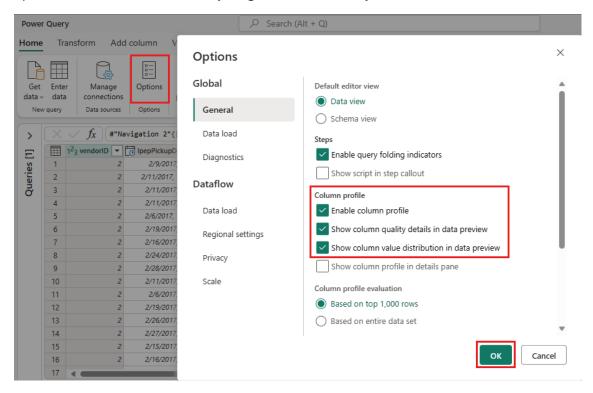
5. Se mostrará el cuadro de diálogo **Elegir datos**. Utilice el panel de navegación para buscar el Lakehouse que creó para el destino en el módulo anterior y seleccione la tabla de datos **Tutorial_Lakehouse**.

Choose data



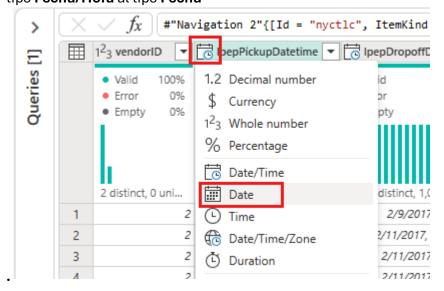
6. *(Opcional)* Una vez que el lienzo esté lleno de datos, puede configurar la información **del perfil de columna**, ya que esto es útil para la creación de perfiles de datos. Puede aplicar la transformación correcta y seleccionar los valores de datos correctos en función de ella.

Para ello, seleccione **Opciones** en el panel de la cinta, luego seleccione las primeras tres opciones en **Perfil de columna** y luego seleccione **Aceptar** .

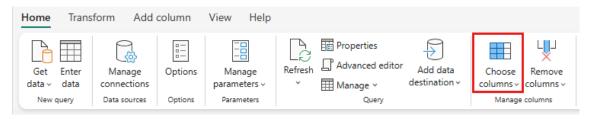


Transformar los datos importados desde Lakehouse

 Seleccione el ícono de tipo de datos en el encabezado de la segunda columna, IpepPickupDatetime, para mostrar un menú desplegable y seleccione el tipo de datos del menú para convertir la columna del tipo Fecha/Hora al tipo Fecha



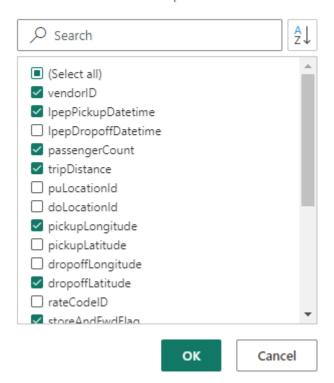
2. *(Opcional)* En la pestaña **Inicio** de la cinta, seleccione la opción **Elegir columnas** del grupo **Administrar columnas** .



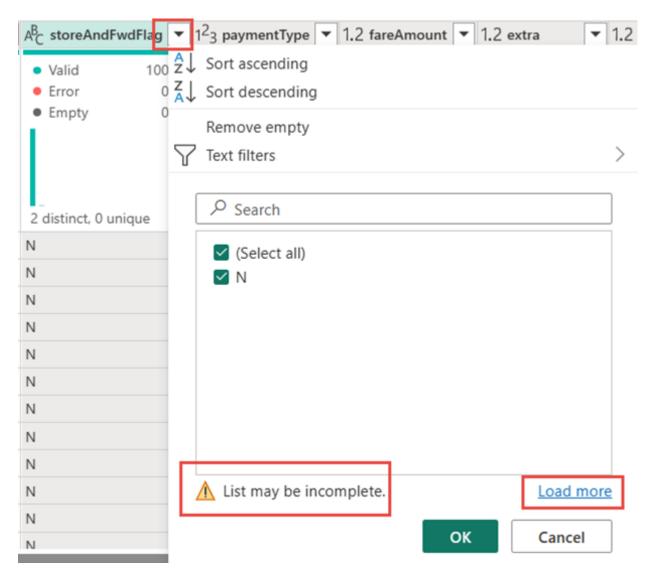
- 3. *(Opcional)* En el cuadro de diálogo **Elegir columnas**, anule la selección de algunas columnas enumeradas aquí y luego seleccione **Aceptar**.
 - lpepDropoffDatetime
 - puLocalizaciónId
 - hacerIdDeUbicación
 - recogidaLatitud
 - Longitud de entrega
 - Código de tasa ID

Choose columns ②

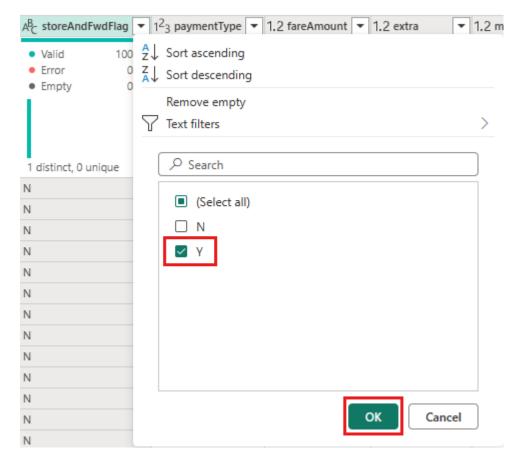
Choose the columns to keep.



4. Seleccione el menú desplegable de filtro y ordenamiento de la columna **storeAndFwdFlag** . (Si ve una advertencia **La lista puede estar incompleta** , seleccione **Cargar más** para ver todos los datos).



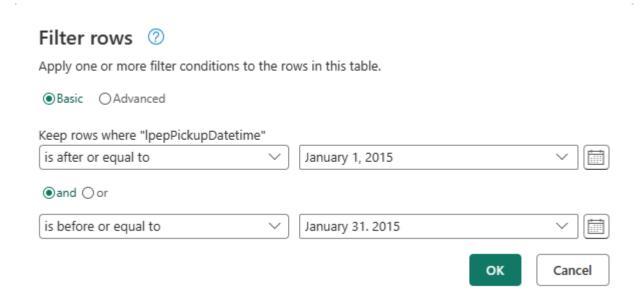
5. Seleccione 'Y' para mostrar sólo las filas donde se aplicó un descuento y luego seleccione **Aceptar** .



6. Seleccione el menú desplegable de filtro y ordenamiento de la columna **IpepPickupDatetime**, **luego seleccione Filtros de fecha** y elija el filtro **Entre...** provisto para los tipos Fecha y Fecha/Hora.



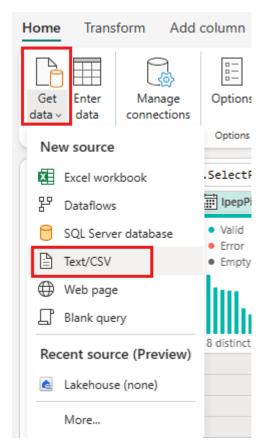
7. En el cuadro de diálogo **Filtrar filas** , seleccione las fechas entre el 1 de enero de 2015 y el 31 de enero de 2015 y, luego, seleccione **Aceptar** .



Conectarse a un archivo CSV que contiene datos de descuento

Ahora, con los datos de los viajes en su lugar, queremos cargar los datos que contienen los respectivos descuentos para cada día y VendorID, y preparar los datos antes de combinarlos con los datos de los viajes.

 Desde la pestaña Inicio en el menú del editor de flujo de datos, seleccione la opción Obtener datos y luego elija Texto/CSV.

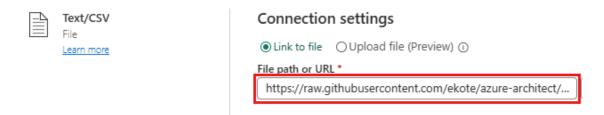


- 2. En el cuadro de diálogo **Conectar a la fuente de datos** , proporcione los siguientes detalles:
 - Ruta del archivo o URL -https://raw.githubusercontent.com/ekote/azurearchitect/master/Generated-NYC-Taxi-Green-Discounts.csv
 - Tipo de autenticación : Anónimo

Luego seleccione Siguiente.

Get data

Connect to data source



3. En el cuadro de diálogo Vista previa de datos del archivo, seleccione Crear.

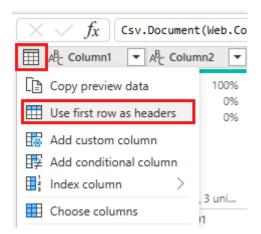
Preview file data

URL: https://raw.githubusercontent.com/ekote/azure-architect/master/Generated-NYC-Taxi-Green-Discounts.csv



Transformar los datos de descuento

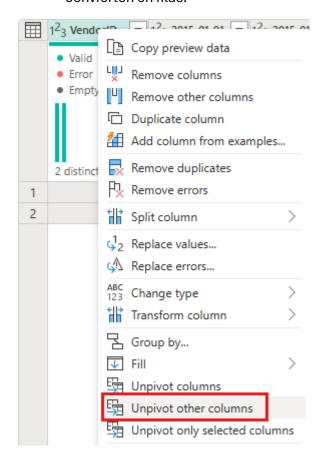
Al revisar los datos, vemos que los encabezados parecen estar en la primera fila.
 Ascienda a encabezados seleccionando el menú contextual de la tabla en la parte superior izquierda del área de la cuadrícula de vista previa para seleccionar Usar la primera fila como encabezados.



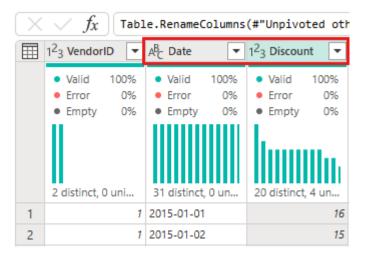
Nota

Después de promover los encabezados, puede ver un nuevo paso agregado al panel **Pasos aplicados** en la parte superior del editor de flujo de datos a los tipos de datos de sus columnas.

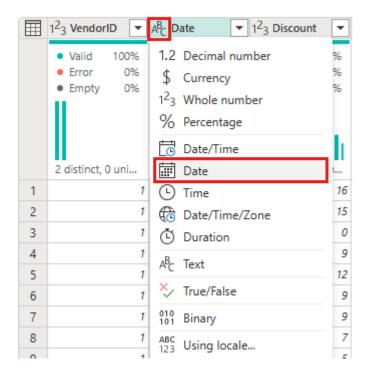
2. Haga clic con el botón derecho en la columna **VendorID** y, en el menú contextual que aparece, seleccione la opción **Anular pivotación de otras columnas** . Esto le permite transformar columnas en pares atributo-valor, donde las columnas se convierten en filas.



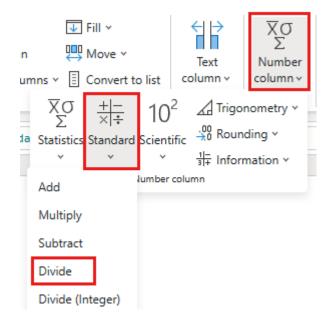
3. Con la tabla sin pivotar, cambie el nombre de las columnas **Atributo** y **Valor** haciendo doble clic en ellas y cambiando **Atributo** a **Fecha** y **Valor** a **Descuento** .



4. Cambie el tipo de datos de la columna Fecha seleccionando el menú de tipo de datos a la izquierda del nombre de la columna y eligiendo **Fecha** .



5. Seleccione la columna **Descuento** y luego seleccione la pestaña **Transformar** en el menú. Seleccione **Columna de números** y luego seleccione Transformaciones numéricas **estándar** en el submenú y elija **Dividir**.



6. En el cuadro de diálogo **Dividir**, ingrese el valor 100.

Divide

Enter a number by which to divide each value in the column.



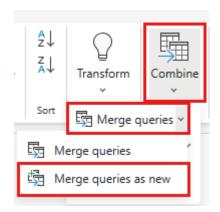
Combina datos de viajes y descuentos

El siguiente paso es combinar ambas tablas en una sola tabla que tenga el descuento que se debe aplicar al viaje y el total ajustado.

1. Primero, active el botón **Vista de diagrama** para poder ver ambas consultas.



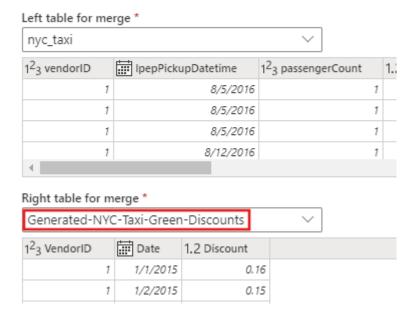
 Seleccione la consulta nyc_taxi y, en la pestaña Inicio , seleccione el menú Combinar y elija Fusionar consultas y, luego, Fusionar consultas como nuevas .



3. En el cuadro de diálogo **Fusionar**, seleccione **Generated-NYC-Taxi-Green- Discounts** en el menú desplegable **Tabla correcta para fusionar** y luego seleccione el ícono de "bombilla" en la parte superior derecha del cuadro de diálogo para ver la asignación sugerida de columnas entre las dos tablas.

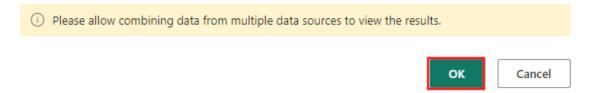


Select tables and matching columns to create a merged table.

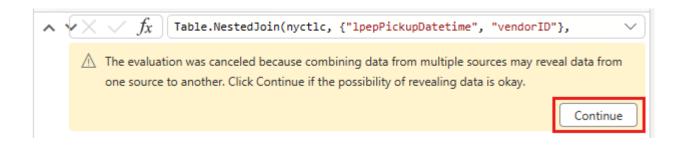


Seleccione cada una de las dos asignaciones de columnas sugeridas, una a la vez, y asigne las columnas VendorID y Date de ambas tablas. Cuando se agregan ambas asignaciones, los encabezados de columna coincidentes se resaltan en cada tabla.

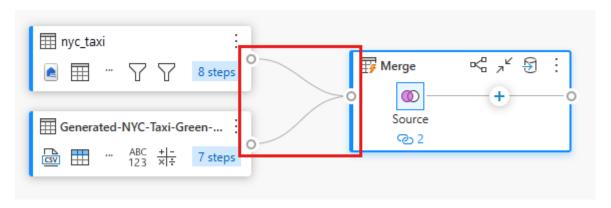
 Aparecerá un mensaje que le solicitará que permita combinar datos de varias fuentes de datos para ver los resultados. Seleccione Aceptar en el cuadro de diálogo Combinar.



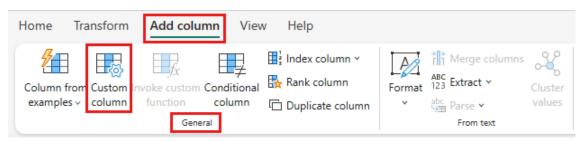
5. En el área de la tabla, verá inicialmente una advertencia que dice: "La evaluación se canceló porque la combinación de datos de múltiples fuentes puede revelar datos de una fuente a otra. Seleccione Continuar si la posibilidad de revelar datos es aceptable". Seleccione Continuar para mostrar los datos combinados.



6. Observe cómo se creó una nueva consulta en la vista Diagrama que muestra la relación de la nueva consulta Merge con las dos consultas que creó anteriormente. Al observar el panel de tabla del editor, desplácese hacia la derecha de la lista de columnas Merge query para ver que hay una nueva columna con valores de tabla. Esta es la columna "Generated NYC Taxi-Green-Discounts" y su tipo es [Table]. En el encabezado de la columna hay un ícono con dos flechas que van en direcciones opuestas, lo que le permite seleccionar columnas de la tabla. Anule la selección de todas las columnas excepto Discount y luego seleccione OK.



7. Ahora que el valor del descuento está en el nivel de fila, podemos crear una nueva columna para calcular el monto total después del descuento. Para ello, seleccione la pestaña **Agregar columna** en la parte superior del editor y elija **Columna personalizada** en el grupo **General**.



8. En el cuadro de diálogo Columna personalizada , puede utilizar el <u>lenguaje de</u> <u>fórmulas de Power Query (también conocido como M)</u> para definir cómo se debe calcular la nueva columna. Ingrese *TotalAfterDiscount* para el **nombre de la nueva columna**, seleccione **Moneda** para el **tipo de datos** y proporcione la siguiente expresión M para la **fórmula de la columna personalizada**:

Custom column ②

Add a column that is computed from other columns or values.



Luego seleccione Aceptar.

 Seleccione la columna TotalAfterDiscount recién creada y luego seleccione la pestaña Transformar en la parte superior de la ventana del editor. En el grupo de columnas Número, seleccione el menú desplegable Redondeo y luego elija Redondear.....



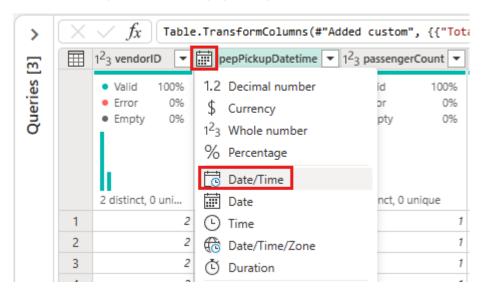
10. En el **cuadro de diálogo Redondear** , ingrese 2 como número de decimales y luego seleccione **Aceptar** .

Round

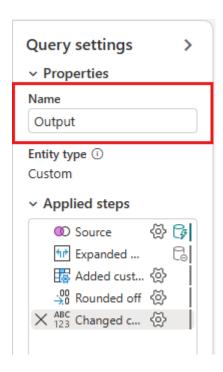
Specify how many decimal places to round to.



11. Cambie el tipo de datos de IpepPickupDatetime de Fecha a Fecha/Hora.



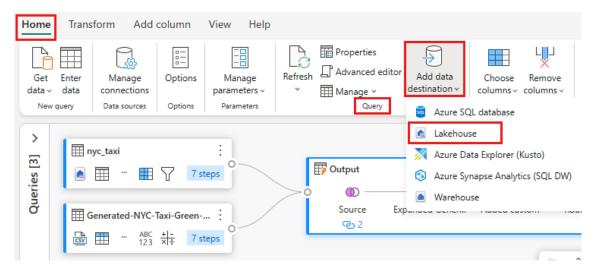
12. Por último, expanda el panel **Configuración de consulta** desde el lado derecho del editor si aún no está expandido y cambie el nombre de la consulta de **Combinar** a **Salida** .



Cargue la consulta de salida en una tabla en Lakehouse

Con la consulta de salida ahora completamente preparada y con los datos listos para ser generados, podemos definir el destino de salida para la consulta.

 Seleccione la consulta de combinación de salida creada anteriormente. Luego, seleccione la pestaña Inicio en el editor y Agregar destino de datos en la agrupación Consulta para seleccionar un destino de Lakehouse.



- 2. En el cuadro de diálogo **Conectarse al destino de datos**, su conexión ya debería estar seleccionada. Seleccione **Siguiente** para continuar.
- 3. En el cuadro de diálogo **Elegir destino**, busque el Lakehouse donde desea cargar los datos y nombre la nueva tabla *nyc_taxi_with_discounts*, luego seleccione **Siguiente** nuevamente.

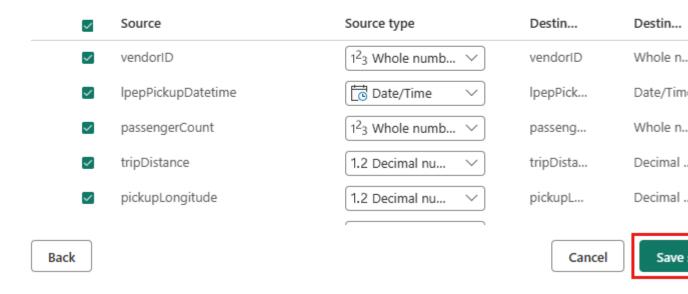
4. En el cuadro de diálogo **Elegir configuración de destino**, deje el método de actualización **Reemplazar** predeterminado, verifique que sus columnas estén asignadas correctamente y seleccione **Guardar configuración**.

Choose destination settings

Update method



Column mapping



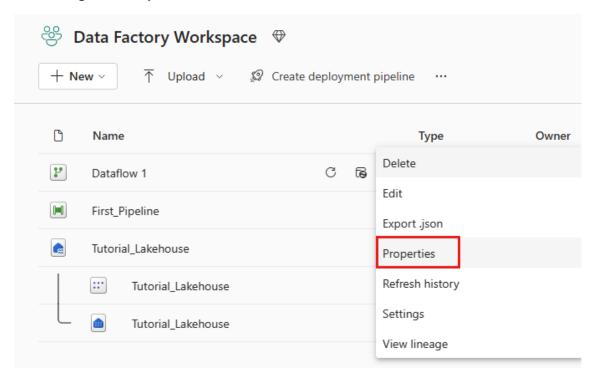
 De regreso a la ventana del editor principal, confirme que ve su destino de salida en el panel de configuración de consulta para la tabla de salida y luego seleccione Publicar.

Importante

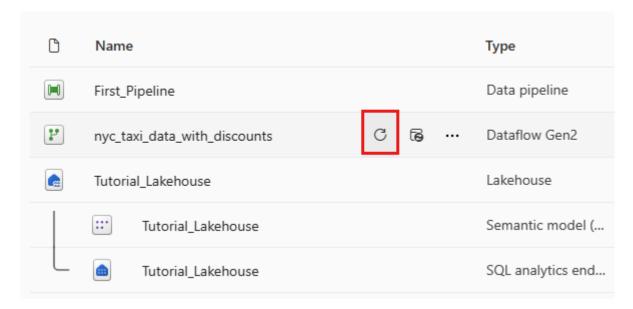
Cuando se crea el primer Dataflow Gen2 en un espacio de trabajo, se aprovisionan los elementos de Lakehouse y Warehouse junto con sus modelos semánticos y puntos de conexión de análisis SQL relacionados. Estos elementos son compartidos por todos los flujos de datos en el espacio de trabajo y son necesarios para que Dataflow Gen2 funcione, no se deben eliminar y no están destinados a ser utilizados directamente por los usuarios. Los elementos son un detalle de implementación de Dataflow Gen2. Los elementos no son visibles en el espacio de trabajo, pero pueden ser accesibles en otras experiencias, como Notebook, SQL-endpoint, Lakehouse y Warehouse. Puede reconocer

los elementos por su prefijo en el nombre. El prefijo de los elementos es "DataflowsStaging".

6. *(Opcional)* En la página del espacio de trabajo, puede cambiar el nombre de su flujo de datos seleccionando los puntos suspensivos a la derecha del nombre del flujo de datos que aparece después de seleccionar la fila y eligiendo **Propiedades** .



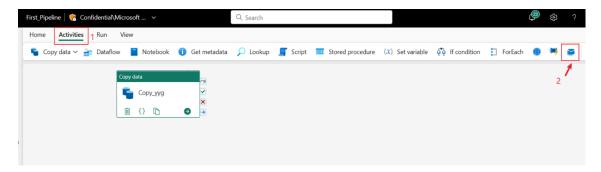
7. Seleccione el ícono de actualización para el flujo de datos después de seleccionar su fila y, cuando termine, debería ver su nueva tabla Lakehouse creada según lo configurado en la configuración **de destino de datos** .



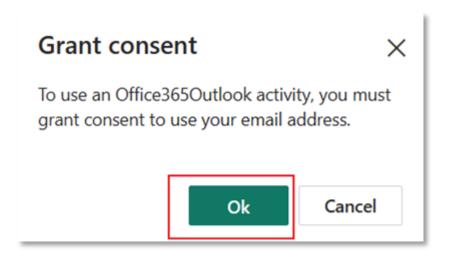
8. Revisa tu Lakehouse para ver la nueva tabla cargada allí.

Agregue una actividad de Outlook de Office 365 a su canalización

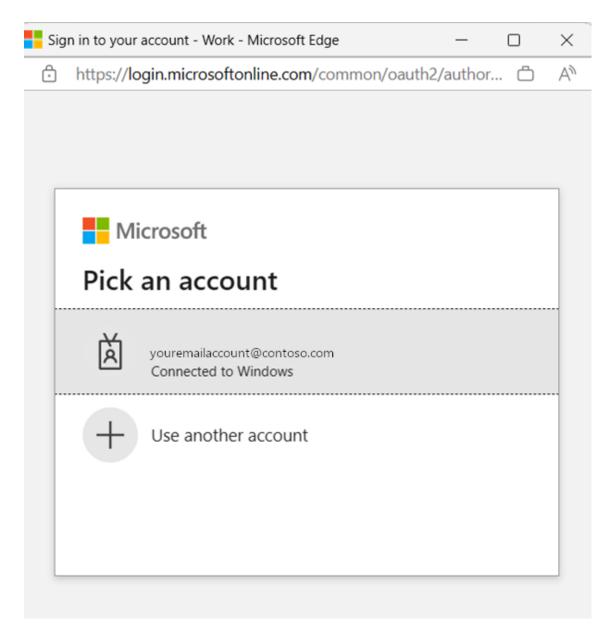
1. Seleccione la pestaña **Actividades** en el editor de canalización y busque la actividad de Office Outlook.



2. Seleccione **Aceptar** para otorgar el consentimiento para utilizar su dirección de correo electrónico.



3. Seleccione la dirección de correo electrónico que desea utilizar.



Nota

Actualmente, el servicio no admite correos electrónicos personales. Debes utilizar una dirección de correo electrónico empresarial.

4. Seleccione **Permitir acceso** para confirmar.



Confirmation required

You are about to provide access to



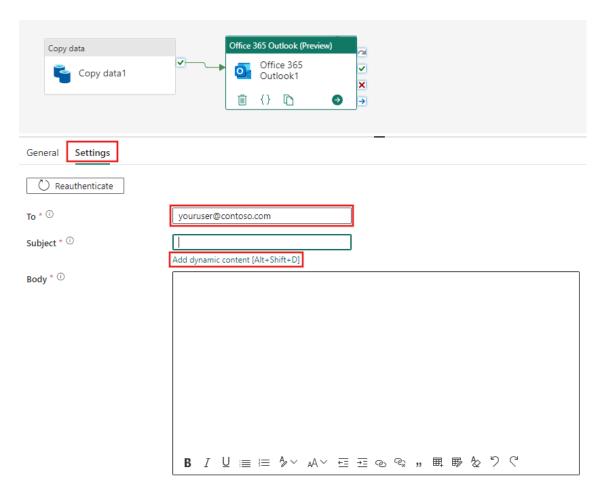
to a connection created by user 12345678-1234-1234-1234-123456789012.



5. Seleccione y arrastre la ruta **En caso de éxito** (una casilla de verificación verde en la parte superior derecha de la actividad en el lienzo de la canalización) desde su actividad Copiar a su nueva actividad Outlook de Office 365.



- 6. Seleccione la actividad de Office 365 Outlook en el lienzo de la canalización y, luego, seleccione la pestaña **Configuración** del área de propiedades debajo del lienzo para configurar el correo electrónico.
 - Introduce tu dirección de correo electrónico en la sección **Para** . Si quieres utilizar varias direcciones, utiliza; para separarlas.
 - Para el Asunto, seleccione el campo para que aparezca la opción Agregar contenido dinámico y luego selecciónelo para mostrar el lienzo del generador de expresiones de canalización.

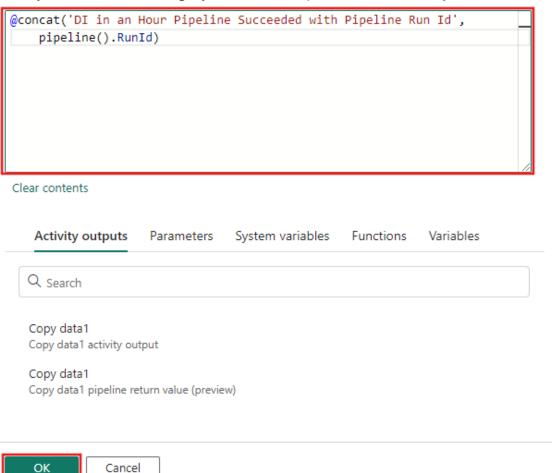


7. Aparece el cuadro de diálogo **Generador de expresiones de canalización** . Ingrese la siguiente expresión y luego seleccione **Aceptar** :

Pipeline expression builder



Add dynamic content below using any combination of expressions, functions and system variables.



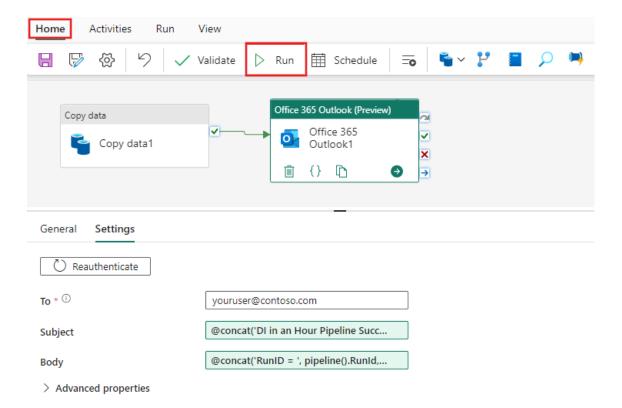
8. Para el **cuerpo**, seleccione el campo nuevamente y elija la opción **Agregar contenido dinámico** cuando aparezca debajo del área de texto. Agregue nuevamente la siguiente expresión en el cuadro de diálogo **Generador de expresiones de canalización** que aparece y luego seleccione **Aceptar**:

@concat('RunID = ', pipeline().RunId, ';', 'Filas copiadas ', activity('Copiar datos1').output.rowsCopied, ';','Rendimiento ', activity('Copiar datos1').output.throughput)

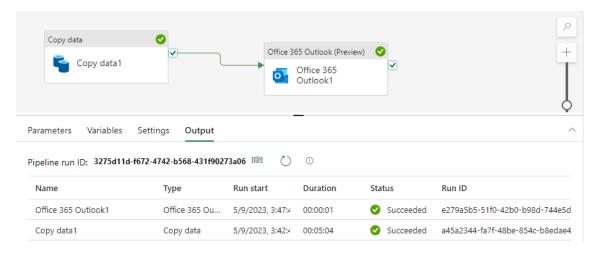
Nota

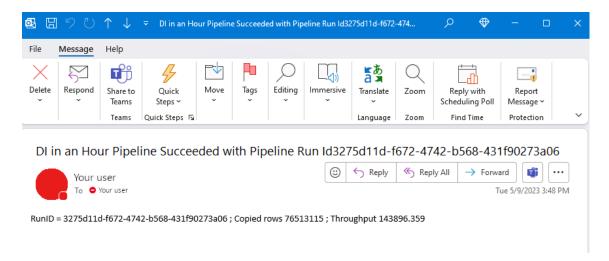
Reemplace **Copiar datos1** con el nombre de su propia actividad de copia de canalización.

9. Por último, seleccione la pestaña **Inicio** en la parte superior del editor de pipeline y elija **Ejecutar** . Luego, seleccione **Guardar y ejecutar** nuevamente en el cuadro de diálogo de confirmación para ejecutar estas actividades.



10. Una vez que el pipeline se haya ejecutado correctamente, revise su correo electrónico para encontrar el correo electrónico de confirmación enviado desde el pipeline.

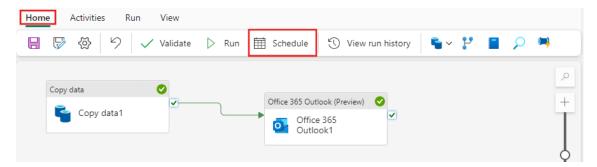




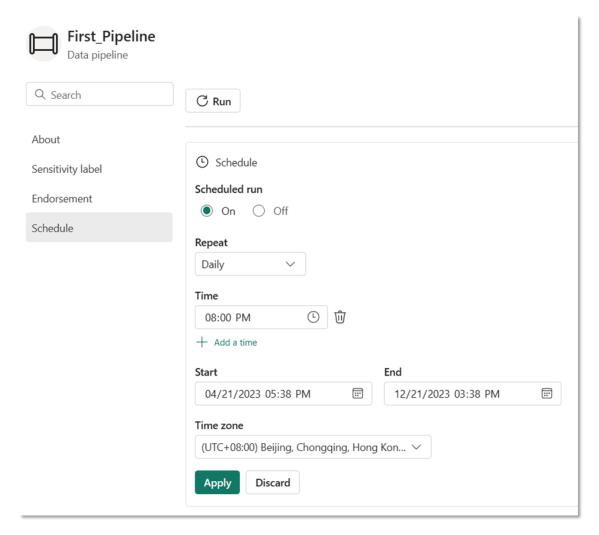
Programar la ejecución del pipeline

Una vez que termine de desarrollar y probar su canalización, puede programarla para que se ejecute automáticamente.

1. En la pestaña **Inicio** de la ventana del editor de canalizaciones, seleccione **Programar** .



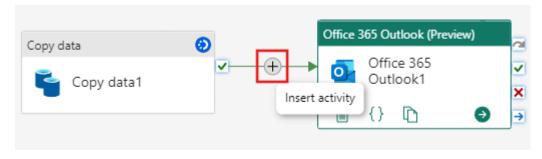
2. Configure el cronograma según sea necesario. En este ejemplo, se programa la ejecución del pipeline todos los días a las 8:00 p. m. hasta fin de año.



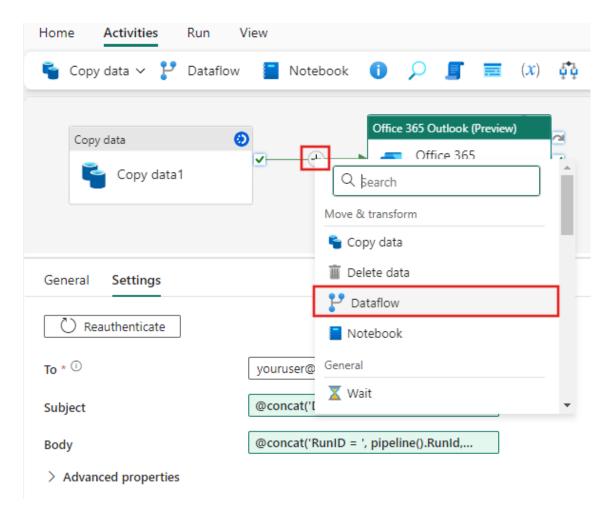
Agregar una actividad de flujo de datos al pipeline

También puede agregar el flujo de datos que creó en <u>el Módulo 2: Crear un flujo de datos</u> <u>en Data Factory</u> en la canalización.

 Coloque el cursor sobre la línea verde que conecta la actividad Copiar y la actividad Office 365 Outlook en el lienzo de su canalización y seleccione el botón + para insertar una nueva actividad.



2. Seleccione Flujo de datos en el menú que aparece.



3. La actividad Dataflow recién creada se inserta entre la actividad Copy y la actividad Office 365 Outlook, y se selecciona automáticamente, mostrando sus propiedades en el área debajo del lienzo.

